

1、(真题 2010 年 14 题) 假定变量 i 、 f 和 d 的数据类型分别为 int 、 float 和 double (int 用补码表示, float 和 double 分别用 IEEE754 单精度和双精度浮点数格式表示), 已知 $i=785$, $f=1.5678\text{e}3$, $d=1.5\text{e}100$ 。若在 32 位机器中执行下列关系表达式, 下面四个表达式结果均为真。

- (I) $i == (\text{int})(\text{float})i$
(II) $f == (\text{float})(\text{int})f$
(III) $f == (\text{float})(\text{double})f$
(IV) $(d+f)-d == f$

A 正确 B 错误

答案: B

解释: 题中三种数据类型强制类型转换的顺序为 $\text{int} \rightarrow \text{float} \rightarrow \text{double}$ 。若将 float 转换为 int , 小数位部分会被舍去, int 是精确到 32 位的整数, 而 float 只保存到 1+23 位, 因此一个 32 位的 int 整数在转换为 float 时也会有损失, 但 i 是 785, 只有 3 位, 低于浮点精度表示的 6-7 位, I 正确。

对于 II, 将 float 型的 f 转换为 int 型, 小数点后的数位丢失, 1567.8 ($1.5678\text{e}3$ 就是 1567.8) 会变为 1567, 与原有的 1567.8 不相等, 结果非真。

对于 III, double 的精度和范围都比 float 大, float 转换为 double 不会有损失, III 正确。
对于 IV, 初看似似乎没有问题, 但浮点运算 $d + f$ 时需要对阶, 对阶后 f 的尾数有效位被舍去而变为 0 (对阶就是从左边开始, 浮点数 d 有 10 的 100 次幂了, 而浮点数 f 在数的低位, double 有效位数只有 15-16 位, 自然对阶时, 低位直接忽略掉了, 10 的 100 次幂到 85 次幂之间的有效位数才是 double 要保存的), 因此 $d + f$ 仍然为 d , 再减去 d 后结果为 0 (因为 double 只能 15 位有效数字), 结果非真。此外, 根据不同类型数据混合运算“类型提升”原则, IV 中等号左边的类型为 double 型, 结果非真。

注意: 从 int 转换为 float 时, 虽然不会发生溢出, 但由于尾数位数的关系, 可能有数据舍入, 影响精度, 而转换为 double 则能保留精度。

什么是对阶: 对阶的原则是小阶向大阶方向化, 误差比较小。之所以这样做是因为若大阶对小阶, 则尾数的数值部分的高位需移出, 而小阶对大阶移出的是尾数的数值部分的低位, 这样损失的精度更小。

2、(真题 2013 年 13 题) 某数采用 IEEE 754 单精度浮点数格式表示为 C640 0000H, 则该数的值是 -1.5×2^{12}

A 正确 B 错误

答案: B

解释: IEEE 754 单精度浮点数格式为 C640 0000H, 二进制格式为 1100 0110 0100 0000 0000 0000 0000 0000, 转换为标准的格式为

S	阶码	尾数
1	1000 1100	100 0000 0000 0000 0000 0000

数符 = 1 表示负数; 阶码值为 $1000\ 1100 - 0111\ 1111 = 0000\ 1101 = 13$; 尾数值为 1.5 (注意其有隐含位, 要加 1)。因此, 浮点数的值为 -1.5×2^{13} 。

3、(2014 年 14 题) float 型数据据常用 IEEE754 单精度浮点格式表示。假设两个 float 型

变量 x 和 y 分 别存放在 32 位寄存器 f_1 和 f_2 中, 若 $(f_1)=CC90\ 0000H$, $(f_2)=B0C0\ 0000H$, 则 x 和 y 之间的关系为 $x < y$ 且符号相同

A 正确 B 错误

答案: A

解释: (f_1) 和 (f_2) 对应的二进制分别是 $(110011001001\cdots)_2$ 和 $(101100001100\cdots)_2$, 根据 IEEE 754 浮点数标准, 可知 (f_1) 的数符为 1, 阶码为 10011001, 尾数为 1.001, 而 (f_2) 的数符为 1, 阶码为 01100001, 尾数为 1.1, 则可知两数均为负数, 符号相同。 (f_1) 的绝对值为 1.001×2^{26} , (f_2) 的绝对值为 1.1×2^{-30} , 则 (f_1) 的绝对值比 (f_2) 的绝对值大, 而符号为负, 真值大小相反, 即 (f_1) 的真值比 (f_2) 的真值小, 即 $x < y$, 选 A。